Catálogo de datasets del TFG

Plataforma de conciencia cibersituacional · Javier Saguar Antona · 5 de noviembre de 2026

33 conjuntos de datos y bases de conocimiento: **6** en uso, **22** en disco sin integrar, **1** previstos, **2** bloqueados y **2** solo registrados. Los descargados están en `data/external/`, con su licencia, origen y SHA-256 en `MANIFEST.md`. La ampliación (FA) solo se hará si el núcleo está cerrado el 28 de febrero de 2027.

Estado. En uso cargado en el pipeline, con resultados. Descargado, sin integrar o Generado, sin integrar: en disco, falta pasarlo por el normalizador. Previsto: aún no se ha descargado. Bloqueado: la descarga oficial no es accesible (error 403 o sin acceso); hay que pedirla a los autores o reintentar. Solo registrado: URL, licencia y tamaño anotados, sin descargar. Las fases F1–F9 son las del ROADMAP; FA es la ampliación condicionada; §3.4, líneas futuras.

Dataset	Descripción	Función en el TFG	Fase	Licencia	Estado
Núcleo del proyecto (fases 1 a 3)					
APT29 día 1 (MITRE ATT&CK Evaluations, OTRF)	Emulación completa del grupo APT29 sobre una red Windows: 196.081 eventos de Sysmon, Security y PowerShell, con el plan de 28 pasos en 10 etapas.	Escenario principal multi-etapa con verdad conocida. Es donde P1, P2 y P3 reconocen campañas; 741 alertas.	F1–F3	MIT	En uso
7 campañas LSASS (OTRF)	Siete volcados de la memoria de LSASS con Metasploit, cada uno con una herramienta distinta (Mimikatz, ProcDump, comsvcs, Out-Minidump, SharpDump, Dumpert, NanoDump).	Prueba de que P1 generaliza: detecta las 7 variantes.	F3	MIT	En uso
Captura atómica comsvcs (OTRF)	184 eventos de un volcado de LSASS con comsvcs.dll.	Referencia de la normalización (100 % de cobertura) y captura limpia de P1.	F1, F3	MIT	En uso
Capturas atómicas de OTRF (~100)	Alrededor de cien capturas de técnicas sueltas, 1,22 millones de eventos.	Entrenamiento y evaluación del detector de anomalías (AUC 0,995 frente a 0,941 del control).	F2	MIT	En uso
Laboratorio de emulación propio	VM Windows 11 aislada con Sysmon y Atomic Red Team: 14.895 eventos (130 maliciosos, 4 técnicas) con tres horas de actividad benigna.	Volumen benigno sostenido y etiquetado exacto. Falta la ruta CSV → OCSF y versionar los guiones.	F2	Propio	Generado, sin integrar
Bases de conocimiento					
Reglas Sigma (SigmaHQ)	Repositorio público de reglas de detección.	2.093 reglas traducidas a OCSF con pySigma; generan las alertas.	F2	DRL 1.1	En uso
MITRE ATT&CK (enterprise)	Catálogo de tácticas y técnicas en STIX.	Etiquetas de las alertas y matriz de cobertura. Se cargará en el grafo de inteligencia.	F2, F4	Términos de MITRE	En uso
AnnoCTR	120 informes de amenazas anotados con técnicas ATT&CK (ZIP oficial de 93,2 MB). Sus 400 + 190 textos se solapan: no son 590 documentos independientes.	Conjunto etiquetado para afinar y evaluar el extractor de técnicas (SecureBERT).	F4	CC BY-SA	Descargado, sin integrar
Informes públicos de amenazas	15 informes públicos de Microsoft en HTML, varios de APT29. Los de CISA no fueron accesibles.	Corpus del extractor de técnicas. Sin anotación de referencia; hay que controlar el sesgo de un solo editor.	F4	Términos de cada editor	Descargado, sin integrar
Indicadores de abuse.ch / OTX	Fuentes abiertas de indicadores de compromiso.	Poblar la plataforma de inteligencia (OpenCTI) o, en el plan B, Neo4j.	F4	Según fuente	Previsto
Ya en disco para la evaluación y la red (clon de OTRF)					
APT29 día 2 (OTRF)	Segundo día de la emulación: 1,7 GB, cuatro veces más que el día 1.	Más ataque y más tráfico benigno sobre la misma red; falsos positivos.	FA.2, F7	MIT	Descargado, sin integrar
Zeek de APT29, días 1 y 2 (OTRF)	Registros de conexiones y DNS en JSON.	Primera fuente de red: cruzar conexiones con las aristas de P2. Primer replay del globo, con ubicaciones ilustrativas.	FA.1	MIT	Descargado, sin integrar
Log4Shell (OTRF)	Explotación de CVE-2021-44228 con Auditd/AUOMS, Sysmon y PCAP.	Conjunto de evaluación y prueba de formato Linux.	F7, FA.4	MIT	Descargado, sin integrar

Dataset	Descripción	Función en el TFG	Fase	Licencia	Estado
GoldenSAML (OTRF)	Falsificación de credenciales federadas: Windows, Azure AD y Microsoft 365.	Cadena de identidad híbrida en el conjunto de evaluación.	F7	MIT	Descargado, sin integrar
Ampliación: Windows externo y Linux					
COMISET LAB (U. P. Comillas)	Laboratorio con ataques etiquetados ATT&CK, 4,91 GB.	Validación externa de la detección Windows sin mapeadores nuevos; muestra filtrada en streaming.	FA.3	CC BY 4.0	Descargado, sin integrar
COMISET REAL	Actividad normal de una red universitaria: ZIP de 31,7 GB (934,5 GB sin comprimir). Piloto de 100.000 registros de dos hosts; el 99 % son Sysmon 10.	Fondo benigno para medir falsas alarmas. El piloto es un prefijo, no una muestra representativa; falta adaptar el envoltorio de Elasticsearch.	FA.3	CC BY 4.0	Descargado, sin integrar
CAM-LDS v2 (AIT)	Campañas Linux con auditoría, autenticación, syslog y flujos, y un manifiesto de pasos con técnicas.	Explotación web → sudo → clave SSH. Prueba de que P3 generaliza a Linux; el escenario 3 se reserva para evaluar.	FA.4	CC BY 4.0	Descargado, sin integrar
AttackMate Evaluation Data	Movimiento lateral por SSH y tres variantes de escalada, generadas con AttackMate, CALDERA y Atomic Red Team.	Comprobar si se detecta lo mismo cuando cambia la herramienta.	FA.4	CC BY 4.0	Descargado, sin integrar
Splunk Attack Data: cron	Log de auditd de una edición de cron (T1053.003) con su ficha.	Verificar el mapeo de auditd a OCSF y una regla.	FA.4	Apache 2.0	Descargado, sin integrar
AIT Alert Data Set	Alertas de Wazuh, Suricata y AMiner con ventanas etiquetadas, 96,2 MB.	Probar el correlador de Flink con alertas externas, aparte de Sigma.	FA.4	CC BY 4.0	Descargado, sin integrar
AIT Log Data Set v2	Actividad normal simulada con auditoría, DNS, Apache y tráfico, y una exfiltración por DNS (`russellmitchell.zip`, 7,13 GB, sin extraer). Etiquetas generadas por reglas.	Fondo benigno Linux y caso de exfiltración (P4).	FA.4	CC BY-NC-SA 4.0	Descargado, sin integrar
Ampliación: disponibilidad (DoS y DDoS)					
BOUN DDoS	Inundaciones SYN y UDP sobre tráfico universitario, por paquete; cuatro ventanas de ataque documentadas. IP anonimizadas o falsificadas.	Primer detector por ventanas en Flink y sus falsas alarmas. No sirve para ubicar atacantes.	FA.5	CC BY 4.0	Descargado, sin integrar
SDN TCP-SYN	Dos PCAP (benigno y SYN) y un CSV de flujos etiquetado de 2,26 MB.	Dos atacantes contra un servicio: medir cuánto tarda la alerta. El CSV sirve para el globo, con ubicaciones simuladas.	FA.5	CC BY 4.0	Descargado, sin integrar
AdDDoSDN	CSV por paquete: 1,69 millones de filas con SYN, UDP, ICMP y ataques lentos.	Cubrir ICMP y el agotamiento de conexiones.	FA.5	MIT	Descargado, sin integrar
DDoS and host background traffic	PCAP con 100 IP de origen y cinco tasas de ataque, sobre fondo de un equipo (3,05 GB).	Probar el detector con más orígenes y distintas cargas.	FA.5	CC BY 4.0	Descargado, sin integrar
CICIDS2017 corregido (DistriNet)	Versión corregida por investigadores (CNS 2022) de un conjunto clásico de intrusiones de red, con DDoS, en CSV.	Familias de red para el detector. Su DDoS va tras NAT: no prueba orígenes distintos ni indisponibilidad.	FA.5	Uso en investigación con cita	Descargado, sin integrar
CSE-CIC-IDS2018, día 20	CSV de 4,05 GB y 7,95 millones de flujos: tráfico benigno y LOIC-HTTP, diez orígenes hacia un destino.	Caso de muchos a uno. Sus horas no llevan AM/PM: no vale como verdad temporal ni para medir latencia.	FA.5	Términos del editor	Descargado, sin integrar
Orion 2026	Cinco días: dos benignos, DoS uno a uno y DDoS de muchos a uno y de muchos a muchos.	Comparar un día benigno con un DDoS de muchos a uno; reservar un día para evaluar.	FA.5	CC BY 4.0	Bloqueado
CICDDoS2019	Ataques de reflexión y amplificación.	Una variante de amplificación, reconstruida por ventanas desde los paquetes.	FA.5	Términos del editor	Bloqueado
Ampliación: otras familias de ataque					
Splunk Attack Data: dcrypt y shadowcopy	Capturas de cifrado de ransomware (T1486) y borrado de instantáneas (T1490), con menos de 0,5 MB en total.	Señales sueltas de impacto. Son de años y hosts distintos: no forman una campaña.	FA.6	Apache 2.0	Descargado, sin integrar
Fuera del alcance (trabajo relacionado)					

Dataset	Descripción	Función en el TFG	Fase	Licencia	Estado
Splunk Attack Data: macOS Gatekeeper	Log de osquery de una evasión de Gatekeeper (T1553.001).	Primera fuente macOS, si alguna vez se amplía.	§3.4	Apache 2.0	Descargado, sin integrar
IoT-23	Flujos de Zeek etiquetados de botnets IoT y tráfico benigno.	Solo red; trabajo relacionado.	§3.4	CC BY 4.0	Solo registrado
DARPA Transparent Computing (E3)	Grafos de procedencia entre procesos, ficheros y conexiones (TB).	No es un grafo de ataque; como mucho, un fragmento.	§3.4	Dominio público	Solo registrado